

2026 MTR 陨石图像分类 Final Report

小组成员：罗媛 孙祺 毛恺诚 林炯扬 江锦星

GitHub 仓库: <https://github.com/HillbillySun/meteorite-dinov2-repro>

HuggingFace: <https://huggingface.co/Eki734/meteorite-dinov2-b14-direct>

ModelScope: <https://www.modelscope.cn/models/QiSunSiu/meteorite-dinov2-b14-direct>

1 引言

本项目面向 2026 MTR 陨石图像二分类任务，目标是在给定图像中判断主体是否为陨石。线上评价指标为 F1 score，因此模型不仅需要提高单样本分类准确性，还需要在 false positive 与 false negative 之间取得平衡。本项目的核心研究问题是：在原始训练图包含尺子、标签纸、桌面和复杂背景，而 Stage2 测试图主要呈现白底、主体居中和背景干净风格的条件下，如何让模型学习陨石本体的纹理、形状和局部结构，而不是依赖背景 shortcut。

该任务的重要性在于，它展示了真实图像分类问题中常见的训练/测试分布不一致现象。若直接使用原始训练图训练，模型可能把拍摄环境、道具或抠图边界误认为类别特征，导致本地验证表现较好但线上泛化下降。因此，本项目与数据科学领域中的数据分布诊断、特征泄漏控制、数据预处理、验证集构造和模型泛化评估密切相关。相比单纯堆叠更大模型，本项目更强调通过数据分析识别误差来源，并用可复现的建模流程解决分布漂移问题。

本文结构如下：第二节介绍数据来源、分布差异、数据问题和 Stage2-style relaxed 预处理；第三节说明最终模型选择、网络结构、训练设置和关键技术；第四节展示主要实验结果，并分析模型优势、过拟合风险和 topK 决策策略；第五节总结优化措施、仍未解决的挑战和后续探索方向；第六节给出结论。项目的核心贡献是构建了一条从测试分布诊断到白底风格数据重构、再到冻结 DINOv2-B/14-reg 特征与 MLP probe 分类的完整 pipeline，并通过 top90 概率排序提交取得 Public F1 = 0.79545。

2 数据集介绍

2.1 数据来源与描述

原始数据来自课程 Kaggle 竞赛 Meteorite-Identification-Stage2，主要包括训练图像 `train_images`、训练标签 `train_labels.csv`、测试图像 `test_images` 和提交模板 `sample_submission.csv`。训练图像格式以 JPG 为主，另有少量 JPEG 与 PNG；具体而言，训练集中 `.jpg` 图像 5029 张、`.jpeg` 图像 60 张、`.png` 图像 9 张。在模型训练前，图像被统一处理为 $392 \times 392 \times 3$ 的输入。标签为二分类，`label=1` 表示陨石，`label=0` 表示非陨石。

表 1: 数据来源与规模统计

数据集	图像数	label=0	label=1	分布与说明
原始训练集	5098	2413	2685	正负样本接近平衡，视觉背景和主体尺度差异大
Stage2 测试集	194	-	-	白底或近白底，主体更居中，背景更干净
Stage2-style relaxed 训练集	11577	5259	6318	由原始训练图重构得到，用于缩小训练/测试视觉域差异

从类别分布看，原始训练集非陨石图像和陨石图像比例分别为 47.33% 与 52.67%；Stage2-style relaxed 训练集中 `label=0` 与 `label=1` 比例分别为 45.43% 与 54.57%。

2.2 数据分析

类别统计显示，训练标签总体接近平衡，不平衡不是影响模型性能的首要因素。更关键的数据统计特性来自图像分辨率和视觉域分布。对 `data/train_images/train_images` 中 5098 张原始训练图统计后，读取失败数为 0；宽度范围为 133–4896 像素，均值为 1076.6，标准差为 762.2；高度范围为 110–3684 像素，均值为 876.5，标准差为 606.9。这说明训练图在拍摄距离、裁剪方式和画布大小上差异较大。原始尺寸不能直接作为统一模型输入；若缩放策略不当，可能造成陨石主体过小、边缘轮廓被削弱，或坑洼纹理、黑色外壳等细粒度特征丢失，从而影响模型对陨石与普通岩石边界样本的判断。

从视觉分布看，原始训练图常出现尺子、比例方块、标签纸、桌面、展示盒等非主体元素，背景颜色、光照和拍摄距离变化较大，部分图像中石头主体偏小、遮挡或边缘不完整。Stage2 测试图则更接近白底商

品图风格，主体居中且背景信息少。若直接使用原始训练图训练，模型容易把拍摄环境、道具或桌面纹理作为类别线索，而不是学习陨石表面的纹理、形状和局部结构。

数据中还存在若干质量问题：第一，rembg 或其他抠图过程可能导致缺失主体、只保留道具或产生边界伪影；第二，陨石与普通岩石在颜色、粗糙表面和坑洼纹理上存在天然模糊边界；第三，随机验证集容易与训练分布过近，造成本地指标虚高。这些问题会使模型过拟合背景 shortcut 或抠图伪特征，并降低线上 Stage2 测试集上的泛化性能。




图 1: rembg 抠图失败案例

2.3 数据预处理




图 2: 数据预处理效果示例

首先对原始训练图使用 rembg 生成较干净的白底前景，用于削弱尺子、方块、标签纸和桌面等背景因素；随后从白底图中裁出主体区域，而不是直接使用整张抠图结果，以减少抠图边界伪影对分类器的影响。

其次，构建 Stage2-style relaxed 训练数据。该过程参考测试集的画布尺寸、主体面积和主体位置分布，将训练主体重新放置到白底画布上；每张原始训练图生成 3 个白底风格变体，并使用 relaxed 过滤规则尽量回收可用样本，同时过滤明显异常主体。关键参数含 min_source_area=0.003、max_source_area=0.90、min_target_area=0.20、max_target_area=0.96、target_area_multiplier=1.08、background_jitter_prob=0.35 和 shadow_prob=0.25。这些步骤的效果是让训练图在背景、主体尺度和画布风格上更接近 Stage2 测试集，同时保留石头主体的真实纹理和形态。

最后，在模型输入前进行尺寸标准化和像素标准化：图像统一采用 Resize(420) + CenterCrop(392)，再使用 ImageNet mean/std normalize。尺寸标准化解决原始图像宽高差异过大的问题，避免模型接收不一致输入；中心裁剪与 Stage2 白底居中主体分布相匹配；ImageNet 标准化则与 DINOv2 预训练输入规范保持一致，有助于稳定特征提取和后续 MLP probe 训练。

3 模型设计与实现

3.1 模型选择

最终模型选择 DINOv2-B/14 with registers 的 frozen feature probe。选择依据有四点：第一，陨石识别依赖纹理、局部结构和形状，DINOv2 自监督视觉表征比图文语义对齐模型更适合细粒度视觉相似性判断；第二，ViT 的 CLS token 提供全局判断，patch mean pooling 保留局部纹理，两者拼接可兼顾整体形态和局部材质；第三，register tokens 能吸收部分全局或异常响应，使 patch 特征更平滑、attention 分布更稳定，并改善依赖局部区域表征的密集预测效果，因此更适合本项目使用 patch mean pooling 进行石头纹理建模；第四，训练数据规模有限且存在噪声，冻结 backbone 只训练轻量 MLP head，比 full fine-tune 更不易记住背景 shortcut。




图 3: 最终分类 pipeline：先缩小 visual domain gap，再利用稳定的自监督视觉表征。

3.2 训练设置与关键技术

表 2: 最终模型配置

项目	配置
Backbone	DINOv2-B/14 with registers, <code>dinov2_vitb14_reg</code> , 全部冻结
特征池化	CLS token + patch mean
分类头	LayerNorm, Dropout(0.45), Linear(512), GELU, Dropout(0.45), Linear(2)
优化器与正则	AdamW, lr=0.0005, weight decay=0.01, label smoothing=0.03
训练策略	positive class weight=1.0, feature mixup alpha=0.05, EMA=0.995, grad clip=1.0
训练轮数	epochs=70, patience=10, seed=3407, early stop metric= <code>topk_f1</code>
验证与测试	fixed mild hard-val split, test horizontal flip TTA, top90 概率排序提交

数据层面的关键技术是 Stage2-style relaxed 数据重构：先用 `rembg` 得到白底前景，再裁出石头主体，并参考 Stage2 测试集的画布尺寸、主体面积和主体位置分布，将训练主体重新放置到白底画布上，从而缩小训练集与测试集之间的 visual domain gap，减少背景 shortcut。为进一步增加样本多样性，每张原始训练图生成约 3 个白底风格变体，通过不同画布、主体尺度和主体位置模拟测试集白底风格下的合理变化，同时保留石头本体纹理。训练层面的关键技术包括 AdamW 解耦权重衰减、label smoothing 降低过度自信、dropout 与 feature-level mixup 抑制小数据过拟合、EMA 和 gradient clipping 稳定训练、topK F1 early stopping 对齐最终提交目标。

3.3 结果展示与分析

下表汇总主要实验分支。最终最高结果来自 DINOv2-B relaxed frozen probe 的 top90 排序提交, Public F1 = 0.79545。

实验表明，性能提升主要来自数据域对齐和 DINOv2 表征，而不是盲目增加模型复杂度。无 Stage2-style 数据增强的 DINOv2-B 仅 0.62790，加入 relaxed 白底重构后显著提升，说明训练/测试风格差异是首要问题。DINOv2 KNN k20 已达 0.77906，证明冻结 embedding 空间对陨石/非陨石有较强可分性；MLP probe 则在此基础上学习更适合任务的决策边界。

表 3: 主要实验对比

方法	关键配置	Public F1	结论
SigLIP fine-tune	rembg/style data, 224 input, partial fine-tune	0.55–0.65	图文语义表征对细粒度纹理不够稳定
ConvNeXt-Base	stage2_style_v2, full fine-tune/probe	0.67441	CNN 纹理特征有用但泛化不足
SwinV2-S	stage2_style_v2, full fine-tune, top86	约 0.6167	本地高、线上弱, 迁移不稳
DINOv3/EVA/AIMv2	frozen probe 或 partial fine-tune	0.69767–0.74871	未超过 DINOv2 主线
DINOv2-B no style aug	原始训练图, 无 Stage2-style 对齐	0.62790	证明风格对齐是关键
DINOv2-B KNN k20	embedding memory bank, top86	0.77906	DINO embedding 空间本身可分
DINOv2-B top90	relaxed frozen probe, seed3407	0.79545	最终最高提交

full fine-tune、LoRA 和 partial fine-tune 未作为最终方案，主要是因为训练集有限且存在背景噪声，更新 backbone 后容易学习 shortcut。实验结果表明，主要挑战来自训练/测试分布差异及其导致的泛化风险。最终采用冻结 backbone + 正则化 MLP probe，并在提交阶段基于概率排序生成二分类标签。

4 改进与优化

4.1 优化措施及效果分析

首先，在数据层面，针对原始训练图与 Stage2 测试图之间的分布差异，项目使用 rembg 去除复杂背景，并构建 Stage2-style relaxed 训练数据。原始训练图中常包含尺子、方块、标签纸、桌面等干扰元素，而 Stage2 测试图多为白底、主体居中的风格。若直接训练，模型容易学习背景 shortcut，而不是陨石本体的纹理和形状。因此，项目从白底图中裁出主体，再参考测试集的画布尺寸、主体面积和位置分布重新生成白底风格训练图。该优化显著缩小了训练/测试 visual domain gap，是最终性能提升的关键；无 Stage2-style 增强的 DINOv2-B 表现明显较低，而 relaxed 重构后最终 Public F1 提升到 0.79545。

但该预处理仍有不足。rembg 和分割方法不能完全避免主体缺失、边缘伪影或道具残留。项目也尝试过 YOLO11m-seg 抠图，虽然能在部分样本中更干净地提取石头主体，但也可能错误保留尺子、方块、人手，或切掉有用轮廓。因此，分割方法更适合作为辅助清洗工具，而不是最终主线。

其次，在模型层面，项目比较了表三中提到的方法。最终选择 DINOv2-B/14 with registers 的 frozen feature probe。该方案冻结 DINOv2 backbone，提取 CLS token 与 patch mean pooling 特征，再训练轻量 MLP head 进行二分类。KNN 实验中，DINOv2-B embedding 在不训练分类头的情况下已经取得较高分数，说明其特征空间本身具有较强可分性；MLP probe 则进一步学习了更适合本任务的决策边界。

训练层面，项目采用 AdamW、weight decay、dropout、label smoothing、positive class weight、feature-level mixup、EMA、gradient clipping 和 topK F1 early stopping 等策略。这些方法主要用于抑制小数据场景下的过拟合，并提高训练稳定性。实验表明，直接 full fine-tune、LoRA 或 last block 微调虽然可能提升本地验证结果，但线上表现不稳定，容易学习背景、抠图边界或验证集特定分布。因此，冻结 backbone、只训练正则化 MLP head 反而更加稳健。不足之处是，frozen probe 的表达能力受到预训练特征限制，对于部分边界样本可能仍不够灵活。

4.2 仍未解决的挑战及可能原因

项目中仍未完全解决的首要挑战是训练/测试分布差异。虽然 Stage2-style relaxed 重构显著缩小了风格差异，但生成数据仍然来源于原始训练图，无法完全模拟真实 Stage2 测试图的拍摄条件、主体边界、光照和清晰度。因此，本地验证集即使经过 hard validation 设计，也仍可能与线上测试分布存在差距。这也是本地 F1 明显高于线上 F1 的主要原因之一。

第二个挑战是自动抠图和主体提取的质量不稳定。rembg 或 YOLO 分割都可能在边缘模糊、主体颜色接近背景、石头与道具接触的情况下产生错误。部分样本会出现主体缺失、边缘被切断、抠图伪影残留或道具未被去除的问题。这类噪声会影响模型训练，使模型学习到不稳定的视觉线索。

第三个挑战是陨石与普通岩石本身存在视觉相似性。部分陨石特征，如黑色熔壳、凹坑、金属光泽和粗糙表面，在单张白底图中并不总是清晰可见；而普通岩石或风化岩石也可能呈现类似外观。同时，磁性、密度、切面结构等关键鉴定信息无法从图片中直接获得。因此，仅依赖图像进行二分类时，边界样本的误判难以完全避免。

此外，ensemble 和模型概率校准也仍不够稳定。多模型融合可以改善局部排序，但不同模型的错误模式和概率分布并不一致，较弱模型可能稀释 DINOv2-B 主模型的有效信号。因此，复杂 ensemble 并未稳定超过最终单模型方案。

4.3 未来可进一步探索的方向

未来首先可以加强数据质量控制。可以对 rembg 异常、主体缺失、边缘伪影明显、道具残留严重的样本进行自动检测和人工复核，减少噪声样本对训练的影响。同时，可以通过聚类或 nearest-neighbor 检查找出分布异常样本，从而进一步提升 Stage2-style 训练集质量。

其次，可以构建更接近 Stage2 测试集的 hard validation。当前本地验证仍不能完全反映线上结果，后续可专门加入白底风格样本、边界样本、低置信度样本和易混淆普通岩石样本，使验证集更接近真实测试分布。这样可以让 early stopping、topK 选择和超参数调节更加可靠。

此外，未来可以尝试调用视觉大语言模型如 Qwen3-VL, Gemini 3.1 Pro 等辅助边界样本决策，或者直接输出预测样本的概率与我们的模型输出概率相加权重。

最后，可以进一步改进集成和测试时增强方法。未来可尝试低权重 rank ensemble、KNN 与 MLP probe 一致性校准、多尺度 DINO TTA 等策略。

5 结论

5.1 项目主要成果和经验教训

本项目构建了一条以数据分布诊断为核心的图像分类 pipeline。项目首先分析了原始训练图与 Stage2 测试图之间的明显风格差异，针对这一问题，项目使用 rembg 和 Stage2-style relaxed 数据重构，将训练样本转化为更接近测试集分布的白底主体图像，从而减少模型对背景 shortcut 的依赖。

在模型层面，项目最终采用冻结的 DINOv2-B/14 with registers 作为视觉特征提取器，结合 CLS token 与 patch mean pooling 表征，并训练正则化 MLP probe 进行二分类。最终通过测试集概率排序选择 top90 作为正类，取得 Public F1 = 0.79545。

本项目的主要经验是，在小规模、细粒度且存在明显训练/测试分布差异的图像任务中，单纯扩大模型或直接 fine-tune backbone 并不一定带来更好结果。相比之下，先诊断数据分布问题，再进行有针对性的数据重构和验证集设计，往往更加重要。同时，冻结强视觉 backbone、只训练轻量且正则化的分类头，可以在减少过拟合风险的同时保持较强泛化能力。项目中的多组 ablation 也表明，LoRA、last block 微调、复杂分割和盲目 ensemble 虽然可能提升局部或本地指标，但在线上测试中并不一定稳定。

5.2 项目创新点和实际应用价值

本项目的创新点主要体现在两个方面。第一，项目没有将陨石识别简单视为常规图像分类问题，而是从训练/测试分布不一致的角度出发，先识别 visual domain gap，再通过 Stage2-style relaxed 数据重构进行针对性修正。这使模型更关注石头主体的纹理、形状和局部结构，而不是背景、道具或拍摄环境。

第二，项目将 DINOv2 自监督视觉表征用于陨石与类陨石图像识别。陨石和普通岩石之间的差异往往是细粒度的，依赖局部纹理、表面结构和整体形态。相比图文语义对齐模型，DINOv2 的通用视觉表征更适合捕捉这类视觉相似性差异。通过 frozen backbone + MLP probe 的方式，项目在性能、稳定性和可复现性之间取得了较好平衡。

实际应用上，该方法可以作为“目标主体识别 + 背景风格迁移 + 冻结视觉基础模型”的通用模板，迁移到矿物识别、材料分类、工业缺陷检测和其他细粒度图像分类任务中。

5.3 未来研究和应用中的潜力

未来，类似的数据科学项目可以在数据质量控制、验证集构造和模型迁移能力三个方向继续发展。首先，在数据层面，可以进一步引入自动化质量检测 and 人工复核机制，筛查 rembg 异常、主体缺失、边缘伪影和道具残留样本，从源头减少训练噪声。

其次，在验证层面，可以建立更接近真实测试分布的 hard validation。当前本地验证仍可能高估模型表现，未来可以专门构造包含白底风格、低置信度样本、易混淆普通岩石和重复样本诊断的验证集，使 early stopping、topK 选择和超参数调节更加可信。

最后，在模型和应用层面，可以探索多尺度 DINO TTA、低权重 rank ensemble。对于实际应用，若能结合图像之外的辅助信息，如密度、磁性、切面结构或来源描述，模型判断将可能更加可靠。因此，本项目不仅完成了一个竞赛型二分类任务，也展示了数据科学方法在真实视觉识别问题中的应用潜力：通过数据分布诊断、稳健表征学习和可复现实验流程，将有限数据转化为可用的决策模型。

6 参考文献

1. Oquab, M., Darcet, T., Moutakanni, T., Vo, H., Szafraniec, M., Khalidov, V., Fernandez, P., Haziza, D., Massa, F., El-Nouby, A., Assran, M., Ballas, N., Galuba, W., Howes, R., Huang, P.-Y., Li, S.-W., Misra, I., Rabbat, M., Sharma, V., Synnaeve, G., Xu, H., Jegou, H., Mairal, J., Labatut, P., Joulin, A., & Bojanowski, P. (2023). DINOv2: Learning Robust Visual Features without Supervision. *arXiv preprint arXiv:2304.07193*.
2. Darcet, T., Oquab, M., Mairal, J., & Bojanowski, P. (2023). Vision Transformers Need Registers. *arXiv preprint arXiv:2309.16588*.
3. Zhai, X., Mustafa, B., Kolesnikov, A., & Beyer, L. (2023). Sigmoid Loss for Language Image Pre-Training. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 11975–11986.
4. Ultralytics. (2024). YOLO11: Ultralytics Documentation. *Ultralytics Docs*. Available at: <https://docs.ultralytics.com/models/yolo11/>.
5. Liu, Z., Mao, H., Wu, C.-Y., Feichtenhofer, C., Darrell, T., & Xie, S. (2022). A ConvNet for the 2020s. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 11976–11986.
6. Liu, Z., Lin, Y., Cao, Y., Hu, H., Wei, Y., Zhang, Z., Lin, S., & Guo, B. (2021). Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 10012–10022.
7. Siméoni, O., Vo, H., Seitzer, M., Baldassarre, F., Oquab, M., Jose, C., Khalidov, V., Szafraniec, M., Yi, S., Ramamonjisoa, M., Massa, F., Haziza, D., Wehrstedt, L., Wang, J., Darcet, T., Moutakanni, T., Sentana, L., Roberts, C., Vedaldi, A., Tolan, J., Brandt, J., Couprie, C., Mairal, J., Jégou, H., Labatut, P., & Bojanowski, P. (2025). DINOv3. *arXiv preprint arXiv:2508.10104*.
8. Fang, Y., Sun, Q., Wang, X., Huang, T., Wang, X., & Cao, Y. (2023). EVA-02: A Visual Representation for Neon Genesis. *arXiv preprint arXiv:2303.11331*.
9. Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Kopf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A., Chilamkurthy, S., Steiner, B., Fang, L., Bai, J., & Chintala, S. (2019). PyTorch: An Imperative Style, High-Performance Deep Learning Library. *Advances in Neural Information Processing Systems (NeurIPS)*, 32.
10. Daniel Gatis. (2024). rembg: Rembg is a tool to remove images background. *GitHub Repository*. Available at: <https://github.com/danielgatis/rembg>.
11. SUSTech STA326. (2026). Meteorite Identification Stage 2. *Kaggle Competition*. Available at: <https://www.kaggle.com/competitions/meteorite-identification-stage-2>.